

- . 1. Transformer 为何使用多头注意力机制？（为什么不使用一个头）
- . 2. Transformer 为什么 Q 和 K 使用不同的权重矩阵生成，为何不能使用同一个值进行自身的点乘？（注意和第一个问题的区别）
- . 3. Transformer 计算 attention 的时候为何选择点乘而不是加法？两者计算复杂度和效果上有什么区别？
- . 4. 为什么在进行 softmax 之前需要对 attention 进行 scaled（为什么除以 dk 的平方根），并使用公式推导进行讲解
- . 5. 在计算 attention score 的时候如何对 padding 做 mask 操作？
- . 6. 为什么在进行多头注意力的时候需要对每个 head 进行降维？（可以参考上面一个问题）
- . 7. 大概讲一下 Transformer 的 Encoder 模块？
- . 8. 为何在获取输入词向量之后需要对矩阵乘以 embedding size 的开方？意义是什么？
- . 9. 简单介绍一下 Transformer 的位置编码？有什么意义和优缺点？
- . 10. 你还了解哪些关于位置编码的技术，各自的优缺点是什么？
- . 11. 简单讲一下 Transformer 中的残差结构以及意义。
- . 12. 为什么 transformer 块使用 LayerNorm 而不是 BatchNorm？LayerNorm 在 Transformer 的位置是哪里？
- . 13. 简答讲一下 BatchNorm 技术，以及它的优缺点。

- . 14.简单描述一下 Transformer 中的前馈神经网络？使用了什么激活函数？相关优缺点？
- . 15.Encoder 端和 Decoder 端是如何进行交互的？（在这里可以问一下关于 seq2seq 的 attention 知识）
- . 16.Decoder 阶段的多头自注意力和 encoder 的多头自注意力有什么区别？（为什么需要 decoder 自注意力需要进行 sequence mask）
- . 17.Transformer 的并行化提现在哪个地方？Decoder 端可以做并行化吗？
- . 18.简单描述一下 wordpiece model 和 byte pair encoding，有实际应用过吗？
- . 19.Transformer 训练的时候学习率是如何设定的？Dropout 是如何设定的，位置在哪里？Dropout 在测试的需要有什么需要注意的吗？
- . 20.引申一个关于 bert 问题，bert 的 mask 为何不学习 transformer 在 attention 处进行屏蔽 score 的技巧？